

Detección de Insumos e Instrumentos Médicos con YOLO26

Avance 3: Entrenamiento e Interpretación de Resultados

Fabián Cartes · Diego Codina · Rodrigo Ortega

Taller de Introducción a Visión por Computadora

Julio 2026

Problema y objetivo

Objetivo

Entrenar un detector que reconozca cuatro insumos e instrumentos médicos en fotos reales, y evaluar qué tan bien funciona y dónde falla.

Motivación

Revisar bandejas de instrumental a mano toma tiempo y produce errores. Un detector permite contar y verificar insumos desde una cámara.

Clases a detectar


Jeringa

Tijera recta

Bisturí

Mascarilla

Metodología



Dataset: Roboflow Universe

"Detección de insumos e instrumentos médicos"

Anotado y exportado en Roboflow (formato YOLO26, licencia CC BY 4.0).

387 imágenes en total

240 entrenamiento · 99 validación · 48 prueba

El export no incluye preprocesamiento ni augmentation.

El problema: el split no está estratificado

Mascarillas casi no aparece en entrenamiento (38 instancias), domina la validación (158) y no existe en el set de prueba (0).

Instancias anotadas por clase y split

Clase	Train	Valid	Test
Jeringa	80	19	9
Tijera recta	93	29	31
Bisturí	83	28	19
Mascarillas	38	158	0
Total	294	234	59

Configuración del experimento

Entorno

- Google Colab · GPU Tesla T4
- Ultralytics 8.4.84 · PyTorch 2.11 (CUDA 12.8)
- OpenCV · NumPy · Matplotlib

Modelo

- YOLO26n preentrenado
- Transfer learning: 606/708 tensores transferidos(no partimos desde cero)

Hiperparámetros

- 100 épocas · batch 16 · imgsz 640
- Optimizador AdamW (lr0 = 0.01, momentum 0.937) (SEÑAL DE ALERTA)
- Early stopping: patience = 20

val: Scanning /content/valid/labels... 99 images, 0 backgrounds, 0 corrupt: 100% ————— 99/99 1.6Kit/s 0.1s

val: New cache created: /content/valid/labels.cache

optimizer: AdamW(lr=0.01, momentum=0.937) with parameter groups 114 weight(decay=0.0), 126 weight(decay=0.0005), 126 bias(decay=0.0)

Plotting labels to /content/runs/detect/train/labels.jpg...

Image sizes 640 train, 640 val

Using 2 dataloader workers


Logging results to **/content/runs/detect/train**

Starting training for 100 epochs...

Ejecución y convergencia

Comportamiento durante las épocas

- La box loss baja de ~ 2.1 a ~ 0.9 en entrenamiento y de ~ 4.0 a ~ 1.5 en validación.
- La pérdida de clasificación cae de 6.31 a 3.99 en las primeras dos épocas, tras un pico inicial.
- El mAP@50 de validación sube de 0.031 en la primera época a 0.829 al final. El mAP@50-95 se estabiliza cerca de 0.56.
- Las pérdidas de validación bajan junto a las de entrenamiento, sin señales de sobreajuste.
- El entrenamiento completó las 100 épocas. El early stopping (patience 20) nunca se activó.



Métricas de desempeño (validación)

0.829

mAP@50

0.563

mAP@50-95

0.773

Precisión


0.774

Recall

Clase	Precisión	Recall	mAP@50	mAP@50-95
Jeringa	0.894	0.890	0.940	0.471
Tijera recta	0.767	0.931	0.921	0.748
Bisturí	0.778	0.752	0.863	0.704
Mascarillas	0.653	0.525	0.593	0.331

Cada imagen tarda 13.6 ms en la Tesla T4, suficiente para trabajar con video en vivo. Mascarillas es la clase más débil: con Recall 0.525, el modelo pierde casi la mitad de las que existen.



Matriz de confusión (validación)



Lectura de la matriz

- De las 158 mascarillas reales, 75 terminan clasificadas como fondo (falsos negativos). El modelo además marca 42 mascarillas donde no hay ninguna (falsos positivos).
- Jeringa: 17 de 19 instancias correctas, sin confusión con otras clases.
- Tijera recta (25 aciertos) y bisturí (20) solo se confunden entre sí, y poco.
- Casi todos los errores tocan la fila o columna background. Al dataset le faltan ejemplos de mascarillas y también imágenes de fondo.

Curvas F1 y Precisión-Recall



El F1 global llega a su máximo (0.76) con confianza 0.236, y ese valor sirve como umbral operativo. En la curva PR, mascarillas (AP 0.595) queda muy por debajo del resto de las clases y arrastra el mAP global a 0.830.

El modelo frente a imágenes reales

DETECCIÓN CORRECTA (TP)



El modelo encuentra la mascarilla puesta en el rostro con confianza 0.79.

FALSO POSITIVO (FP)



El certificado del empaque aparece detectado como bisturí con confianza 0.26. El modelo nunca vio imágenes de fondo al entrenar.

FALSO NEGATIVO (FN)



Un mango de bisturí real pasa sin ser detectado. Esa variante del instrumento casi no existe en el dataset.

Con un umbral de confianza de 0.4, el falso positivo desaparece y la mascarilla se sigue detectando.

Interpretación crítica y mejoras

Hallazgos

- Mascarillas rinde mal porque casi no existe en entrenamiento: 38 instancias contra 158 en validación.
- Jeringa se detecta bien (mAP@50 0.94) pero con cajas poco ajustadas (mAP@50-95 0.471). Hay que revisar esas anotaciones.
- Sin imágenes de fondo en el dataset, el modelo inventa detecciones sobre objetos con texto y bordes rectos.
- El set de prueba no sirve para evaluar mascarillas: tiene cero instancias.

Mejoras propuestas

1. Rehacer el split en Roboflow, estratificado 70/20/10. Es el arreglo más barato y el de mayor impacto.
2. Sumar ejemplos de mascarillas al entrenamiento, de 38 a al menos 150.
3. Aplicar augmentation offline a las clases con menos ejemplos.
4. Agregar cerca de un 10 % de imágenes de fondo (negativas).
5. Bajar lr0 a 0.001 para AdamW, o dejar el optimizador en automático.
6. Probar YOLO26s y fijar el umbral de confianza en 0.4.

CONCLUSIONES

¿Es viable el modelo?

¡Es viable!

mAP@50 de 0.829 con solo 387 imágenes y un modelo nano de 2,6 M de parámetros.

La limitación es el dataset, no la arquitectura.

Desbalance de clases, split no estratificado y ausencia de imágenes de fondo.

Próximo paso.

Con el split corregido y más ejemplos de mascarillas, la meta es superar 0.85 de mAP@50 en las cuatro clases.